

הערכת עומק רחפן מתמונה


Z Drone final project •

Maoz daniel
Noam Solow



שבוע 1

27/11/2025



רקע ומוטיבציה לזיהוי תלת-ממדי

למה בכלל צריך לזהות עומק רחפן?
• מעקב, זיהוי והתרעה בזמן אמת.

פתרונות קיימים כיום:

- מערכות סטראו (2 מצלמות) / חיישני עומק ייעודיים.
- נותנים דיוק טוב אבל יקרים, כבדים ומורכבים לתפעול/כיוול.

הפתרון שלנו:

- פתרון מונוקולרי - מצלמה אחת בלבד.
- זול יותר, פשוט יותר לפריסה.

האתגר המרכזי:

- להסיק מידע תלת-ממדי (Z) מתוך תמונה דו-ממדית אחת.



הגדרת המשימה והיקף

חלוקת הפרויקט:

- צוות אחר מטפל ב-X,Y, אנחנו אחראים על Z.

קלט למערכת:

- תמונה, Bounding Box של הרחפן, ו-Ground Truth של Z מהסימולטור.

פלט:

- Z במטרים - עומק/מרחק הרחפן מהמצלמה.

סוג הדאטה:

- דאטה סינתטי בלבד (Unreal Engine) עם GT מדויק לכל פריים.





תרשים זרימה ודיוק התוצאות

Process Flow

Unreal Engine Video → YOLO Detection → Depth Estimation → 3D Reconstruction → Kalman Tracking → GUI Output

Localization Accuracy:

Distance Range	Relative Error	Absolute Error
20-50m	5-8%	±2-4m
50-100m	8-12%	±4-12m
100-150m	12-18%	±12-27m



יצירת דאטה סינתטי ב-Unreal

- הדאטה שלנו מגיע מסימולציה ב-Unreal Engine בלבד.
- Unreal מספק Ground Truth מדויק של מיקום הרחפן לכל פריים, בלי איסוף דאטה אמיתי יקר.
- חובה לשמור את מיקום הרחפן במערכת הצירים של המצלמה (Camera Space) כדי שה-Z יהיה "מרחק מהמצלמה".
- נדרש סנכרון מלא בין צילום הפריים ללוג ה-GT אותו frame index כדי לא לזהם את הדאטה.
נייצר גיוון שיטתי בדאטה: טווחי מרחק שונים, רקעים ותנאי תאורה/מזג אוויר, כדי שהמודל יהיה רובסטי.



דגשים קריטיים במצלמה ובקואורדינטות

- ה-Z Ground Truth חייב להיות ב-Camera Space (מרחק מהמצלמה).
- פרמטרי המצלמה: fx , fy , cx , cy , FOV חייבים להתאים לחישובים שלנו.
- אי-התאמה בפרמטרים תגרום לשגיאות.


בחירת ארכיטקטורת עומק

MiDaS - בסיס מהיר ופשוט שמחזיר עומק יחסי טוב בלי אימון התחלתי.

ZoeDepth - מודל מתקדם יותר שנותן עומק קרוב למטרי ומשפר דיוק אחרי הבייסליין, בנוי על MiDaS.

Depth Anything - מודל עומק חדש וחזק מאוד, נבחן אם נצטרך קפיצת דיוק נוספת.





איך מחשבים ערך Z

- מריצים את מודל העומק על כל התמונה ומקבלים Depth Map.
- משתמשים ב-Bounding Box כדי לבודד את אזור הרחפן במפת העומק.
- מחלצים ערך עומק מייצג לרחפן (למשל median / mean בתוך התיבה).
- התוצאה בשלב הזה היא Z יחסי, לפני המרה למטרים.
- נמיר למטרים בעזרת Scale Calibration נוסף פקטור אם צריך.




הכלים המרכזיים בפרויקט

- Unreal Engine 5
- GPU של החברה


- Python ו-PyTorch
- Jupyter Notebook / JupyterLab
- OpenCV
- Scikit-learn (אופציונאלי)
- Matplotlib

שבוע 2

3/12/2025



פתיחת repository



המודלים שבחנו

MiDaS (DPT_Large)

BEiT 512 (DPT_BEiT_L_512)

ZoeDepth (ZoeD_N)

ZoeDepth (ZoeD_K)

MiDaS (DPT_Large)

- פותח ע"י **Intel ISL** כחלק ממשפחת MiDaS.
- מפיק **עומק יחסי** מתמונה אחת בלבד.
- מבוסס על **Vision Transformer** ללכידת מבנה סצנה.
- את הפלט הגדלנו לרזולוציית המקור ושמרנו כ- heatmap להשוואה.


Original Image (RGB)

Screenshot 175500



MiDaS Output (DPT Large)

Depth Map




BEiT 512 (DPT_BEiT_L_512)

- מבוסס על **מודל** BEiT - Vision Transformer חדש יותר ומדויק יותר בזיהוי מבנים עדינים.
- עובד ברזולוציית 512×512 , לעומת המודל הקודם.
- מפיק **גבולות אובייקטים חדים יותר** ודיוק טוב יותר באזורים מורכבים וצפופים.
- מאומן על סטים מתקדמים יותר.

MiDaS (DPT Large)

Screenshot 175434



MiDaS v3.1 (BEiT 512)

Screenshot 175434



ZoeDepth (ZoeD_N)

- מודל המתבסס על MiDaS.
- מפיק עומק מטרי אמיתי (במטרים) בניגוד ל MiDaS - שמפיק עומק יחסי בלבד.
- מצטיין בהפרדת אובייקטים חדה וזיהוי פרטים קטנים בסצנות מורכבות.
- מתאים במיוחד לסביבות כלליות/ביתיות (Indoor/General) ומספק עומק יציב בטווחים קצרים- בינוניים.

כיוון הצבעים הפוך מאשר MiDaS, לכן ניקח בהסתייגות את התוצאות הויזואליות.

ZoeDepth (Metric)

Screenshot 175434



MiDaS v3.1 (BEiT 512)

Screenshot 175434



ZoeDepth (ZoeD_K)

- גרסה מותאמת לחוץ (Outdoor), מאומנת על KITTI עם טווח עומק גדול יותר.
- מפיקה עומק מטרי מדויק, במיוחד למרחקים ארוכים (כבישים, רחובות, נוף).
- שומרת על פרטים גם באזורים רחוקים, בהשוואה ל-ZoeD_N.
- יציבה יותר בסצנות עם תאורה חזקה ושמיים פתוחים.

Image 2: Screenshot 175500

ZoeD_N (Indoor)

Path: output_zoe_N\zoe_NScreenshot...



ZoeD_K (Outdoor)

Path: output_zoe_k\zoek_Screenshot...



Original (RGB)



MiDaS (Base)



MiDaS (BEiT 512)



ZoeDepth (Indoor)




ZoeDepth (Outdoor)



Original (RGB)



MiDaS (Base)



MiDaS (BEiT 512)



ZoeDepth (Indoor)




ZoeDepth (Outdoor)




Original (RGB)



MiDaS (Base)



MiDaS (BEiT 512)



ZoeDepth (Indoor)




ZoeDepth (Outdoor)



Image Center Line (y=305)



Depth Profile Comparison (Normalized 0-1)



שבוע 3

3/12/2025

דרישות:

- להריץ את המודל על טרנספורמציות שונות של תמונות (masks) ולראות את ההשפעות.
- להריץ את המודל על תמונות שונות של רחפנים: תחילה על רקע של שמיים, ולאחר מכן עם אובייקטים אחרים בתמונה.
- להכין ארכיטקטורה של אימון המודל.



cars.png



fewPeople.png



houses.png



menyPeople.png



newYork.png



playGround.png



telAviv.png



trees.png



תמונות סביבתיות שונות

Mask על התמונות

עבור כל תמונה, ביצענו שלושה סוגים של masks:



Slices


Random

manual



slice

עבור כל תמונה חצינו אותה לחצאים ולרביעיות



random



עבור כל תמונה הוצאנו 15 bounding boxes במקומים רנדומליים.

manual






עבור כל תמונה הוצאנו אובייקט
מסוים באופן ידני.



```
MANUAL_INPUTS = [  
    ... # cars  
    ... (0, [30, 180, 230, 280]), ... # <--- green car  
    ... (0, [0, 220, 400, 415]), ... # <--- left red car  
    ... (0, [185, 285, 586, 612]), ... # <--- blue car  
    ... (0, [310, 200, 440, 260]), ... # <--- white car  
    ... (0, [440, 200, 570, 300]), ... # <--- back red car left  
    ... (0, [655, 190, 790, 300]), ... # <--- black car  
    ... (0, [660, 285, 1122, 624]), ... # <--- front red strip car  
    ... (0, [784, 196, 935, 250]), ... # <--- beck right red not most rig  
    ... (0, [920, 221, 1254, 396]), ... # <--- gold car  
    ... (0, [1053, 175, 1233, 256]), ... # <--- most right red car  
    ... (0, [0, 112, 1280, 179]), ... # <--- landscape background  
    ... (0, [20, 188, 1250, 646]), ... # <--- all cars  
  
    ... # few people:  
    ... (1, [220, 720, 466, 969]), ... # <--- women kicking ball
```

ZoeDepth_K הרצת



	image_name	mask_type	bbox	area_ratio	mae	rmse	max_err	min_err	pct_err_lt1	pct_err_lt5	pct_err_lt10
0	cars	slice	[0, 0, 775, 391]	0.826638	5.119406	7.817008	41.0	0.0	0.197871	0.581087	0.833835
1	cars	slice	[0, 0, 640, 391]	0.682643	42.798630	90.384842	247.0	0.0	0.108572	0.481214	0.628720
2	cars	slice	[0, 0, 640, 473]	0.825806	36.458153	85.695587	253.0	0.0	0.119728	0.537744	0.782419
3	cars	manual	[0, 112, 775, 179]	0.141649	32.750332	38.392006	91.0	0.0	0.012248	0.060857	0.126182
4	cars	manual	[0, 220, 400, 415]	0.212780	20.474346	30.008686	81.0	0.0	0.020974	0.192833	0.499769

סטטיסטיקות

(לא סופיים)



הרצת המודלים על תמונות שונות של רחפנים

- תמונות עם רקע שמייים נקי.
- תמונות עם אובייקטים נוספים.

```
try:
    print("⌚ Loading Depth Anything V2...")
    da_checkpoint = "depth-anything/Depth-Anything-V2-Small-hf"
    da_processor = AutoImageProcessor.from_pretrained(da_checkpoint)
    da_model = AutoModelForDepthEstimation.from_pretrained(da_checkpoint).to(device)
    models['DepthAnything'] = (da_model, da_processor)
    print("Depth Anything loaded.")
```

הוספנו להשוואת המודלים את DepthEverything:
• מודל חדיש עם שיפור משמעותי ברזולוציה קבועה ובדיוק הגבולות.

DepthAnything

(השתמשנו בגרסת small, המתאימה לעיבוד על המחשב
המקומי שלנו)



תמונות עם רקע שמייים

Original: drone2.png



DepthAnything




MiDaS_BEiT



ZoeD_N



ZoeD_K



Original: drone1.png



DepthAnything




MiDaS_BEiT




ZoeD_N




ZoeD_K




Original: drone4.png



DepthAnything




MiDaS_BEiT



ZoeD_N



ZoeD_K



Original: drone5.png




DepthAnything



MiDaS_BEiT



ZoeD_N



ZoeD_K



Original: drone3.png



DepthAnything




MiDaS_BEiT



ZoeD_N



ZoeD_K



תמונות מורכבות יותר

Original: drone4.png



DepthAnything



MiDaS_BEiT



ZoeD_N



ZoeD_K




Original: drone1.png




DepthAnything



MiDaS_BEiT



ZoeD_N



ZoeD_K



Original: drone3.png



DepthAnything



MiDaS_BEiT



ZoeD_N



ZoeD_K



Original: drone5.png



DepthAnything



MiDaS_BEiT



ZoeD_N




ZoeD_K




Original: drone6.png



DepthAnything




MiDaS_BEiT



ZoeD_N



ZoeD_K



Original: drone2.png



DepthAnything



MiDaS_BEiT



ZoeD_N



ZoeD_K



• **סיכונים** את המודל על טיפוסים מרמזות שונות של תמונות (masks, crops) ולראות את ההשפעות. 

נצטרך לשפר אותן ולהגיע לתוצאות ברורות

• להריץ את המודל על תמונות שונות של רחפנים: תחילה על רקע של שמיים, ולאחר מכן עם אשיות קטנים אחרים בתמונה. 

• להכין ארכיטקטורה של אימון המודל.




שבוע 4

16.12.2025


דרישות:

- .mask->depth VS depth-> mask
- בניית ארכיטקטורה ראשונית לאימון.
- מוכנים של pipelines בדיקה על של yolo.







mask->depth
VS depth->
mask



Local Depth
(Zoe saw only this)




Global Depth
(Zoe saw full -> We masked it)



Local Depth
(Zoe saw only this)




Global Depth
(Zoe saw full -> We masked it)




Local Depth
(Zoe saw only this)




Global Depth
(Zoe saw full -> We masked it)



Local Depth
(Zoe saw only this)




Global Depth
(Zoe saw full -> We masked it)



ארכיטקטורת המודל

MONOCULAR DRONE DISTANCE ESTIMATION – HYBRID VISION PIPELINE



"אימון" המודל

- עבור כל פריים: מאתרים את הרחפן בתמונה, מחשבים מפת עומק, מחלצים ערך עומק יחסי באזור הרחפן, מצמידים לערך מרחק אמת מהדאטאס
- לאחר איסוף הדגימות מבצעים רגרסיה לינארית (Least Squares), בשביל לקבל פקטור יציב
- פקטור זה נשמר ומשמש בזמן הריצה
- (בעתיד נייצר פקטורי S שונים עבור מצבי מזג אוויר שונים)

```
def run_calibration_pipeline( images, true_distances, detection_mode="demo", depth_mode="demo",
                             detector_model=None, depth_model=None,):
    """ ... """
    relative_depths = []
    z_true_values = []

    for image, z_true in zip(images, true_distances):

        # ---- Detection ----
        if detection_mode == "demo":
            detection = detect_drone_demo(image)
        else:
            detection = detect_drone(image, detector_model)

        bbox = detection["bbox"]

        # ---- Depth estimation ----
        if depth_mode == "demo":
            depth_map = estimate_relative_depth_demo(image)
        else:
            depth_map = estimate_relative_depth(image, depth_model)

        # ---- Relative depth at drone location ----
        d_rel = extract_drone_relative_depth(depth_map, bbox)

        relative_depths.append(d_rel)
        z_true_values.append(z_true)

    # ---- Scale calibration ----
    s = compute_scale_factor(relative_depths, z_true_values)

    return s
```

הרצה בזמן אמת

- שלב זה רץ בזמן אמת על כל פריים בנפרד
- משתמשים בערך שנקבע בזמן הכיול והמרה לעומק
 $Z = s \cdot d_{\text{relative}}$
- הפלט: קורדינטות (X,Y,Z) במטרים

```
def run_runtime_pipeline(image, scale_factor, intrinsics, detection_mode="demo", depth_mode="demo", detector_model=None, depth_model=None):  
    """ ...  
  
    # ---- Detection ----  
    if detection_mode == "demo":  
        detection = detect_drone_demo(image)  
    else:  
        detection = detect_drone(image, detector_model)  
  
    bbox = detection["bbox"]  
    x_pixel = detection["x_pixel"]  
    y_pixel = detection["y_pixel"]  
  
    # ---- Depth estimation ----  
    if depth_mode == "demo":  
        depth_map = estimate_relative_depth_demo(image)  
    else:  
        depth_map = estimate_relative_depth(image, depth_model)  
  
    # ---- Relative depth at drone location ----  
    d_rel = extract_drone_relative_depth(depth_map, bbox)  
  
    # ---- Metric depth ----  
    z_hat = scale_factor * d_rel  
  
    # ---- Geometry ----  
    position_3d = reconstruct_drone_position(  
        x_pixel=x_pixel,  
        y_pixel=y_pixel,  
        z=z_hat,  
        intrinsics=intrinsics,  
    )  
  
    return position_3d
```

שבוע 5 + 6

30.12.2025

דרישות:

- להשוות בין mask ואז depth, depth ואז mask עבור תמונות של רחפנים - גם תמונות אמיתיות וגם תמונות מהאינטרנט.
- לבדוק האם יש דאטסט של רחפנים עם העומק שלהם.
- לראות האם אנחנו לא נרצה לחפש קבוע s, אלא פרמטר שיש לו קשר לגודל הbb.
- חיבור למחשב המרוחק והתקנת unreal engine בו.

Mask -> Depth vs Depth -> Mask

Original RGB



Original Depth




Orig Depth + Mask



Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB




Original Depth



Orig Depth + Mask



Masked RGB Depth




Orig Depth Cropped




Cropped RGB Depth



Original RGB




Original Depth




Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB



Original Depth



Orig Depth + Mask



Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth




Original RGB




Original Depth




Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB




Original Depth



Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB




Original Depth



Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped




Cropped RGB Depth




Original RGB




Original Depth



Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth




Original RGB




Original Depth



Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped




Cropped RGB Depth




Original RGB




Original Depth



Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped




Cropped RGB Depth




Original RGB




Original Depth



Orig Depth + Mask



Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB




Original Depth



Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB




Original Depth



Orig Depth + Mask



Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



Original RGB




Original Depth




Orig Depth + Mask




Masked RGB Depth



Orig Depth Cropped



Cropped RGB Depth



ממצאים

לפי הניסויים שלנו, $\text{depth} \rightarrow \text{mask}$ נתן את העומק היחסי בצורה יותר ברורה ומשמעותית מאשר $\text{mask} \rightarrow \text{depth}$

בנוסף, $\text{depth} \rightarrow \text{mask}$ זיהה את הרחפן בצורה יותר טובה וגם את המרחק יותר טוב.

$\text{Crop} \rightarrow \text{depth}$ זיהה את הרחפן בצורה יותר טובה אבל הראה כל חלק של הרחפן במרחק יותר גדול ממה שצריך עבור אובייקט אחד.

אבל היו מצבים שבו אם לא עושים crop קודם אז הdepth לא זיהה את הרחפן.




```
<annotation>
  <folder>train</folder>
  <filename>1520.jpg</filename>
  <path>C:\Users\96987\Desktop\2\train\1520.jpg</path>
  <source>
    <database>Unknown</database>
  </source>
  <size>
    <width>3840</width>
    <height>2160</height>
    <depth>3</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>UAV</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>904</xmin>
      <ymin>642</ymin>
      <xmax>1091</xmax>
      <ymax>719</ymax>
    </bndbox>
  </object>
</annotation>
```




דאטאסט קיים-רחפנים ומרחק מהמצלמה

Det-Fly

- רחפן מצלם רחפן אחר תוך כדי תעופה
- למעלה מ-13,000 תמונות מגוונות ב-4K
- אין תיוג ישיר של מרחק במטרים מהמצלמה
- ישנם נתונים כמו דגם המצלמה, הרזולוציה וגודל האובייקט בתמונה (בפיקסלים), כך שניתן להעריך את המרחק האמיתי במטרים באמצעות חישוב גיאומטרי.

<https://github.com/Jake-WU/Det-Fly>

האם s הוא לא קבוע, אלא תלוי בגודל ה- bb ?



- כשהרחפן רחוק, ה-Bounding Box קטן מאוד (מעט פיקסלים). במצב כזה, מודלי הערכת העומק עלולים לא להצליח/ לא להתייחס לרחפן

- בקצוות התמונה או במרחקים גדולים, הקשר הגיאומטרי עלול להתעוות

מימוש הפונקציה $s(bb)$


1. כיול לפי מקטעים

חלוקת נתוני האימון לטווחים, וחישוב Least Squares נפרד לכל קבוצה. "פונקציית מדרגות"





2. רגרסיה פולינומית


העברת קו שעובר דרך הנקודות בצורה הטובה ביותר $s(bb) = \dots + a_1 * bb^2 + a_2 * bb + c$

תחילה נשתמש בפקטור קבוע, לאחר מכן נבצע כיול לפי מקטעים, ולבסוף נתקדם לרגרסיה פולינומית (אם יהיה בכך צורך)



חיבור למחשב המרוחק והתקנת unreal engine בו.





שבוע 7

7.1.2025

דרישות:

- לחקור על ה unreal engine
- לחכות לתשובות
- להתחיל לעבוד על סקריפט בשביל dataset

Distance From Camera 500



הבדל מרחקים

Distance From Camera 5000



Distance From Camera 50



שאלות שיש לנו:

שאלה 1: כמה
קריטי כל
המדדים?

TIME

9:35 AM

DATE

March 26 2021

LOCATION




Lat: 51.179 Long: -1.826

Time Zone: 0

WEATHER

 Clear Skies

לגבי איך נשמור?



לגבי הBB?



שבוע 8

18.2.26

דרישות:

- להתחיל לייצר דאטאסט
- לייצר סקריפט עבור שמירת הנתונים

ייצור הדאטאסט והמבנה

Name	Date modified	Type
 depth_20	18/01/2026 21:18	File folder
 depth_30	26/01/2026 16:20	File folder
 depth_40	26/01/2026 18:05	File folder
 depth_50	21/01/2026 13:49	File folder
 depth_60	18/01/2026 17:54	File folder
 depth_70	18/01/2026 17:54	File folder
 depth_80	19/01/2026 15:25	File folder
 depth_100	21/01/2026 13:40	File folder
 depth_115	18/01/2026 17:56	File folder
 depth_125	18/01/2026 17:56	File folder
 depth_150	21/01/2026 10:05	File folder

 clear_sky	18/01/2026 21:05	File folder
 light_rain	18/01/2026 22:01	File folder
...		
 8PM	26/01/2026 12:02	File folder
 10AM	18/01/2026 19:58	File folder

ייצור הדאטאסט והמבנה



HighresScreensh
ot00000_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00001_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00002_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00003_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00004_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00005_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00006_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00007_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00008_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00009_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00010_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00011_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00012_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00013_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00014_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00015_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00016_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00017_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00018_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00019_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00020_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00021_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00022_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00023_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00024_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00025_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00027_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00028_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00029_depth_2
0_clear_sky_10A
M.png



HighresScreensh
ot00030_depth_2
0_clear_sky_10A
M.png

יצור הדאטאסט והמבנה



תכנון הדאטאסט

- מרחקים 20,30,40 - 100 בכל תת תיקיה: 2×100 זמנים 2×2 מזגי אוויר * 3
מרחקים = $1200 = 30\%$
- מרחקים 50,60,70,80 - 100 בכל תת תיקייה: 2×100 זמנים 2×2 מזגי
אוויר * 4 מרחקים = $1600 = 40\%$
- מרחקים 100,115,125,150 : 75 בכל תת תיקיה: 2×75 זמנים 2×2 מזגי
אוויר * 4 מרחקים = $1200 = 30\%$

Recommended Distribution:

- **20-50m:** 30% of samples (high accuracy zone)
- **50-100m:** 40% of samples (primary operational range)
- **100-150m:** 30% of samples (challenging long-range)

אוטומציה לניהול הדאטאסט

- יצירה אוטומטית של היררכית תיקיות לפי פרמטרים (עומק, מז"א, שעה)
- מספור מחדש של תמונות קיימות לביטול "חורים" ומניעת התנגשויות שמות
- הוספת תמונות חדשות לתיקייה בהמשך המספור הקיים
- שינוי שם הקובץ כך שיכיל את כל המטא דאטא הרלוונטי לאימון

```
# --- Configuration ---
$SourceDir = "C:\Users\depthlev\Downloads\ProjectGA\ProjectGA\ProjectGA\Saved\Screenshots\Windows"
$DestBaseDir = "C:\Users\depthlev\Desktop\droneImages\dataset"

# Valid Options
$ValidWeather = @("clear_sky", "foggy", "light_rain")
$ValidTime = @("10AM", "8PM")

Write-Host "--- Drone Dataset Organizer (Collision Fix Mode) ---" -ForegroundColor Cyan

# 1. Ask for Real Depth
do {
    $DepthInput = Read-Host "Enter REAL Depth (Number only, e.g. 5)"
    if ($DepthInput -eq "exit") { Write-Host "Exiting..."; exit }
    if ($DepthInput -notmatch "^[0-9]+$") { Write-Host "Invalid input." -ForegroundColor Red }
} until ($DepthInput -match "^[0-9]+$")
$DepthVal = [int]$DepthInput

# 2. Ask for Weather
do {
    $Weather = Read-Host "Enter Weather (clear_sky, foggy, light_rain)"
    if ($Weather -eq "exit") { Write-Host "Exiting..."; exit }
    if ($ValidWeather -notcontains $Weather) { Write-Host "Invalid input." -ForegroundColor Red }
} until ($ValidWeather -contains $Weather)

# 3. Ask for Time
do {
    $RawTime = Read-Host "Enter Time of Day (10AM, 8PM)"
    if ($RawTime -eq "exit") { Write-Host "Exiting..."; exit }
    $TimeOfDay = $RawTime.ToUpper()
    if ($ValidTime -notcontains $TimeOfDay) { Write-Host "Invalid input." -ForegroundColor Red }
} until ($ValidTime -contains $TimeOfDay)

# 4. Construct Destination Path
$DestDir = Join-Path $DestBaseDir "depth_$DepthVal\$Weather\$TimeOfDay"

# 5. Create Directory if Missing
if (-not (Test-Path -Path $DestDir)) {
    Write-Host "Creating directory: $DestDir" -ForegroundColor Yellow
    New-Item -ItemType Directory -Path $DestDir -Force | Out-Null
}

# --- LOGIC PART A: RENUMBER EXISTING FILES (SAFE METHOD) ---
Write-Host "`n[Phase A] Checking existing files in destination..." -ForegroundColor Cyan


# Step 1: Rename ALL existing files to a TEMP name to prevent collisions
# (This solves the error you saw)
$ExistingFiles = Get-ChildItem -Path $DestDir -Filter "*.png" | Sort-Object Name
$TempPrefix = "TEMP_RENAMING_"

foreach ($File in $ExistingFiles) {
    # Check if already temp (in case of rerun after crash)
    if ($File.Name -notmatch "^[0-9]+_TEMP_RENAMING_") {
        $TempName = $TempPrefix + $File.Name
        Rename-Item -Path $File.FullName -NewName $TempName -Force
    }
}

# Step 2: Now rename from TEMP to FINAL sequence
$TempFiles = Get-ChildItem -Path $DestDir -Filter "${TempPrefix}*.png" | Sort-Object Name
$CurrentSeqID = 1

foreach ($File in $TempFiles) {
    $SeqIdStr = "{0:d5}" -f $CurrentSeqID
    $NewName = "${SeqIdStr}_depth_${DepthVal}_${Weather}_${TimeOfDay}.png"
    Rename-Item -Path $File.FullName -NewName $NewName -Force
    $CurrentSeqID++
}
```

אוטומציה לניהול הדאטאסט



```
Windows PowerShell

--- Drone Dataset Organizer (Collision Fix Mode) ---
Enter REAL Depth (Number only, e.g. 5): 50
Enter Weather (clear_sky, foggy, light_rain): clear_sky
Enter Time of Day (10AM, 8PM): 10AM
```

בעיות

- קושי רב בייצור כללי של התמונות
- הרבה תמונות ללא רחפן, עם עיוותים ותקיעות
- הסימולציה לא מותאמת למרחקים גדולים (+60)
- השעה שנבחרה ללילה- חשוכה מדי

מצב הדאטאסט כרגע

Dataset Generation Progress (4000 Total Images Planned)

Path/Folder	Status	Images Found	Planned	Notes/Issues
dataset\depth_20\clear_sky\10AM	Complete	100	100	-
dataset\depth_20\clear_sky\8PM	Missing	0	100	No images found
dataset\depth_20\light_rain\10AM	Complete	100	100	-
dataset\depth_20\light_rain\8PM	Missing	0	100	No images found
dataset\depth_30\clear_sky\10AM	Needs Filtering	100	100	Filter from 250 total
dataset\depth_30\clear_sky\8PM	Missing	0	100	No images found
dataset\depth_30\light_rain\10AM	Needs Filtering	100	100	Filter from 250 total
dataset\depth_30\light_rain\8PM	Missing	0	100	No images found
dataset\depth_40\clear_sky\10AM	Complete	100	100	-
dataset\depth_40\clear_sky\8PM	Missing	0	100	No images found
dataset\depth_40\light_rain\10AM	Complete	100	100	-
dataset\depth_40\light_rain\8PM	Missing	0	100	No images found
dataset\depth_50\clear_sky\10AM	Incomplete	72	100	Missing 28 images
dataset\depth_50\clear_sky\8PM	Missing	0	100	No images found
dataset\depth_50\light_rain\10AM	Incomplete	70	100	Missing 30 images
dataset\depth_50\light_rain\8PM	Missing	0	100	No images found
dataset\depth_60 - depth_150 (All Weather/Times)	Simulation Error	0	1600 (approx.)	Drone not detected in simulation

- 18.5 % מהכולל
- 46.36% מהטווח שביכולתנו כרגע
- 92.75% בטווח כרגע ללא הלילה (יתכן שנקדים את שעת הערב)

שבוע 9

11.3.26

דרישות:

- להמשיך לייצר דאטאסט
- להתאים ולייצר bounding boxes עבור התמונות

המשך ייצור הדאטאסט

- כדי להגדיל את הדאטאסט תחת המגבלות, הוחלט שבכל תת תיקייה יהיו 300 תמונות במקום 100
- כרגע, עדיין לא ייצרנו תמונות בלילה (8PM חשוכה מדי) - צריך לחשוב על שעה מתאימה
- לאחר סינון מקיף של תמונות, מבנה הדאטאסט כרגע:

המשך ייצור הדאטאסט-מצב ביניים

Summary by DepthFolders

1.		20		579 photos (30.11% of total)	
2.		30		589 photos (30.63% of total)	
3.		40		642 photos (33.39% of total)	
4.		50		113 photos (5.88% of total)	
5.		60		No photos	
6.		80		No photos	
8.		100		No photos	
9.		115		No photos	
10.		125		No photos	
11.		150		No photos	

Detailed Sub-folder Statistics

(Non-Zero project % only)

Folder Path	Image Count (Project %)
 depth_20\clear_sky\10AM	276 (14.35%)
 depth_20\light_rain\10AM	303 (15.76%)
 depth_30\clear_sky\10AM	289 (15.03%)
 depth_30\light_rain\10AM	300 (15.60%)
 depth_40\clear_sky\10AM	323 (16.80%)
 depth_40\light_rain\10AM	319 (16.59%)
 depth_50\clear_sky\10AM	72 (3.74%)
 depth_50\light_rain\10AM	41 (2.13%)

 Total: **1,923** photos 

Drone Location:
X: -880.31
Y: 1219.57
Z: 620.69



Drone Location:
X: 2391.59
Y: 5995.34
Z: 689.62



Drone Location:
X: 1090.18
Y: 4980.87
Z: 877.97



Bounding boxes

• התחלת ייצור bounding boxes עבור כל תמונה

Name	Date modified	Type	Size
 HighresScreenshot00001_depth_30_clear_sky_1...	26/01/2026 12:04	PNG File	6,650 KB
 HighresScreenshot00001_depth_30_clear_sky_1...	10/03/2026 11:51	Text Document	1 KB
 HighresScreenshot00002_depth_30_clear_sky_1...	26/01/2026 12:04	PNG File	6,963 KB
 HighresScreenshot00002_depth_30_clear_sky_1...	10/03/2026 11:52	Text Document	1 KB
 HighresScreenshot00003_depth_30_clear_sky_1...	26/01/2026 12:04	PNG File	7,035 KB
 HighresScreenshot00003_depth_30_clear_sky_1...	10/03/2026 11:52	Text Document	1 KB
 HighresScreenshot00004_depth_30_clear_sky_1...	26/01/2026 12:05	PNG File	8,380 KB
 HighresScreenshot00004_depth_30_clear_sky_1...	10/03/2026 11:52	Text Document	1 KB
 HighresScreenshot00005_depth_30_clear_sky_1...	26/01/2026 12:05	PNG File	7,884 KB
 HighresScreenshot00005 depth 30 clear sky 1...	10/03/2026 11:52	Text Document	1 KB



0 0.517513 0.586850 0.009717 0.011036

מצב ביניים - Bounding boxes

DATASET BOUNDING BOX (BB) TAGGING STATISTICS

Global Summary



Total Images:
1,923





Total BB Files (Tagged Images):
868



45.14%
Global Percentage of
Images with Bounding Boxes

Detailed Statistics by Folder Structure



שאלות להמשך

- כרגע אין אופציה לייצר תמונות למרחקים ארוכים. האם הסימולציה המעודכנת מוכנה?
- עדיין ישנו קושי רב בייצור תמונות- האם ניתן לעדכן את הסימולציה כך שתייצר רק תמונות שהרחפן נמצא בהן?
- כמעט בכל התמונות, הרחפן מיוצר במרכז התמונה, ולכן גם הבב דומים בערכם- כרגע כנראה ויהיה overfitting עבור הנתונים האלו. האם ניתן להוסיף רנדומיזציה למיקום הרחפן והזווית שלו?
- האם ישנה בעייתיות שהדאטאסט שלנו מורכב מעומקים בקפיצות של עשרות? (20/30/40)

0.011036	0.013225	0.524415	0.498418	0
0.011996	0.012955	0.526211	0.504544	0
0.009597	0.013495	0.525332	0.498161	0
0.013435	0.013765	0.524042	0.501890	0
0.011036	0.009717	0.586850	0.517513	0


שבוע 10


18.3.26

דרישות:

- להתחיל לעבוד עם הסימולציה החדשה
- להמשיך ליצר bounding boxes עבור התמונות
- להתחיל לעבוד עם התמונות של המרחקים הקרובים

הסימולציה החדשה






dataset	21/01/2026 13:50	File folder
Clean-Dataset.ps1	05/03/2026 2:33	Windows
Get-DatasetStats.ps1	10/03/2026 16:01	Windows
OrganizeImages.ps1	16/03/2026 17:05	Windows

הוספנו ושינינו את התוכנות שלנו להתמודד עם הסימולציה החדש

בעיות בסימולציה:
בעיה ראשונה הוא
שבמרחקים
גדולים לא רואים
רחפן




בעיות בסימולציה:
בעיה שניה היא
שאין שום דבר חוץ
מהרחפן



ניסינו דרכים שונות
להוסיף עולם



בעיות בסימולציה: בעיה שלישית היא שהרחפן נשאר באמצע התמונה ולא מסתובב



לסיכום

- להתחיל לעבוד עם המולטי-החדשה 
- להמשיך ליצר bounding boxes עבור התמונות 
- להתחיל לעבוד ~~התמונות של המרחקים הקרובים~~ 

שבוע 11

14.4.26

דרישות:

- לעבוד על הסימולציה ולשפר.
- לסיים את הדאטה סט.
- לעבוד על הדוח אמצע ולעדכן.
- מתחילים את השלב הבא.



שדרוג סימולציית הרחפן

מה הם השידרוגים?

שיפור הריאליזם הסביבתי ושילוב מבנים בסביבה.

שיפור של מיקומי רחפן למניעת הסתרות בנינים.

יצירת מגוון באמצעות זוויות מצלמה רנדומליות.

שדרוג השמיים והתאורה למראה ריאליסטי יותר.

הטמעת bounding boxes אוטומטיות לכלל התמונות.

חישוב סטיית הרחפן ביחס למרכז התמונה שלא יהיה באמצע.

חישוב מתמטי מדויק של מרחק הרחפן.

סייום הדאטה

15,000 תמונות

DEPTH VS WEATHER/TIME MATRIX					
Depth	clear_sky_10AM	clear_sky_8PM	light_rain_10AM	light_rain_8PM	DEPTH_TOTAL
depth_20	409	200	400	249	1258
depth_30	404	200	401	200	1205
depth_40	481	200	400	200	1281
depth_50	472	200	400	200	1272
depth_60	403	217	403	248	1271
depth_70	451	200	400	203	1254
depth_80	464	200	400	218	1282
depth_90	437	200	400	200	1237
depth_100	404	200	400	200	1204
depth_115	400	200	400	326	1326
depth_125	400	200	403	200	1203
depth_150	400	200	402	205	1207
CONDITION_TOTAL	5125	2417	4809	2649	15000

שאלות למשך העבודה

שבוע 12

29.4.26

דרישות:

- התנעת תהליך העבודה על המודל.
- פיתוח וניתוח של קוד הראשוני.
- ביצוע ניסויים ראשוניים והפקת תובנות.



קוד ניסיון ראשון



run_extract_features.py



run_study.py

path	Label_path	True_distance	Relative_depth	Bbox_width_px	Bbox_height_px	Bbox_width_norm	Bbox_height_norm	Bbox_area_ratio
ers\depthle	C:\Users\depthle	100	5.24	18	18	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	5.58	21	20	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0.6	26	16	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0.55	22	8	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0	25	6	0.01	0	0
ers\depthle	C:\Users\depthle	100	0	23	12	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	1.14	38	7	0.01	0	0
ers\depthle	C:\Users\depthle	100	0	19	8	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0	19	10	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	2.3	21	13	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0.32	28	7	0.01	0	0
ers\depthle	C:\Users\depthle	100	0	26	9	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0	32	8	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	2.97	18	19	0.01	0.01	0
ers\depthle	C:\Users\depthle	100	0.11	32	6	0.01	0	0
ers\depthle	C:\Users\depthle	100	0.01	20	10	0.01	0.01	0

attempt > artifacts > reports > correlations.csv

```
feature_name,pearson_correlation,count
relative_depth,0.03493088918504435,14800
bbox_width_px,-0.7617336897409628,14800
bbox_height_px,-0.6287412060801267,14800
bbox_width_norm,-0.7583646503026575,14800
bbox_height_norm,-0.6296041438064942,14800
bbox_area_ratio,-0.5353576746625561,14800
bbox_aspect_ratio,-0.03722366922147013,14800
bbox_center_x_norm,-0.009359538056096779,14800
bbox_center_y_norm,-0.04439421802277377,14800
```


Run exact features

מאפיינים שחולצו (Features)

- **עומק:** ערך חציוני (Median) שהושג מה depth map על התמונה בתוך הBB.
- **גיאומטריה:** רוחב/גובה (פיקסלים ומנורמל), יחס שטח ויחס גובה-רוחב.
- **מטא-דאטה:** תנאי סביבה (מזג אוויר: גשם/בהיר זמן: יום/לילה).

סקירת תהליך (Process Overview)

- **טעינת נתונים:** שימוש ב- DroneDatasetLoader לעיבוד 14,800 דגימות סינתטיות.
- **הרצת מודל:** הפעלת מודל עומק (depthAnything v2) על תמונות RGB מלאות.
- **חילוץ ממוקד:** בידוד אזור הרחפן בעזרת קואורדינטות ה-Bounding Box
- **אסטרטגיית שמירה:** המרת נתוני העומק לקובץ csv המאפשר הרצה מהירה של שלב הכיול.

למה עומק חציוני?

• עמידות:

מונע "זליגת רקע" (שמיים או קרקע) לתוך חישוב העומק של הרחפן.

• יציבות:

פחות רגיש לרעשי עומק וערכים קיצוניים לעומת ממוצע רגיל.

• דיוק:

מספק נתון אמין יותר לפני השטח של הרחפן מאשר פיקסל בודד.

כחלק מהמחקר
נבדוק עוד
אופציות בהמשך

המודלים שנבחנו

Scale only •

$$Z \approx s * d_{rel} \quad •$$

- מודל הבסיס, להשוואה עם המודלים האחרים

depth_only_linear •

$$Z \approx b_0 + b_1 * d_{rel} \quad •$$

- שיפור קטן למודל 1

- בדיקה האם הוספת נקודת חיתוך מועילה

depth_geometry_metadata_linear •

- כל הפרמטרים נלקחים בחשבון

- time_of_day, weather, relative_depth ונתוני BB

Run study

תהליך הערכת המודל (The Evaluation Process)

- השוואה מול אמת (Ground Truth): התהליך לוקח את המרחק שהמודל חזה ומשווה אותו למרחק האמיתי מהסימולציה
- חישוב המרחק הממוצע של השגיאה וזיהוי דפוסים (האם המודל תמיד חוזה מרחק גדול מדי או קטן מדי?).
- השגיאות לא נבדקות רק כציון כללי, אלא מחולקות לפי קטגוריות:
 - טווחים: קרוב (20-60 m), בינוני (70-100 m), ורחוק (115-150 m).
 - תנאי סביבה: מזג אוויר ושעה.

פירוט המדדים

1

MAE

- ממוצע השגיאה במטרים (בערך מוחלט).
- "כמה מטרים אנחנו טועים בממוצע?" זהו המדד האינטואיטיבי ביותר

2

Relative Error

- היחס בין השגיאה לבין המרחק האמיתי (באחוזים).
- טעות של 2 מטרים במרחק של 10 מטרים היא קריטית, אבל במרחק של 100 מטרים היא זניחה. המדד הזה נותן פרופורציה.

3

RMSE (Root Mean Square Error):

- שורש ממוצע הריבועים של השגיאות.
- "מעניש" שגיאות גדולות מאוד בצורה חמורה יותר מ-MAE. עוזר לנו לראות אם יש למודל נפילות קיצוניות מדי פעם.

4

R^2 (Coefficient of Determination):

- מדד בין 0 ל-1 (או שלילי במקרה של מודל גרוע).
- כמה המודל שלנו מצליח להסביר את השונות בנתונים. ציון גבוה (קרוב ל-1) אומר שהמודל עוקב היטב אחרי המגמה של המרחק.

Range	Count	MAE (m)	Mean Relative Error
Near	913	16.01	49.69%
Mid	746	9.37	11.45%
Far	561	18.90	13.88%

תוצאות



Model	MAE (m)	Mean Relative Error	RMSE (m)	R ²
scale_only	47.75	75.11%	58.19	-1.33
depth_only_linear	32.11	65.57%	38.14	-0.00
depth_geometry_metadata_linear	14.50	27.79%	18.29	0.77

בעיות /
שאלות

העומק לא משפיע בצורה חזקה

הBB משפיע בצורה חזקה מדי

הלילה והגשם הצליחו הכי הרבה-
צריך לבדוק למה

הטווח הקרוב טעה יותר מאשר
הטווח הרחוק

העומק לא משפיע בצורה חזקה

```
relative_depth,0.03493088918504435,14800
```


הBB משפיע בצורה חזקה מדי

- המודל המלא הצליח כנראה בגלל גודל ה-Bbox שקשור ישירות למרחק בנתונים שלנו.

```
bbox_width_px,-0.7617336897409628,14800  
bbox_height_px,-0.6287412060801267,14800  
bbox_width_norm,-0.7583646503026575,14800  
bbox_height_norm,-0.6296041438064942,14800  
bbox_area_ratio,-0.5353576746625561,14800
```

הלילה והגשם הצליחו הכי הרבה- צריך לבדוק למה

המודל הציג ביצועים מעט טובים יותר בתנאי גשם קל ובשעות הערב לעומת שמיים בהירים ושעות הבוקר.

אנחנו לא מסיקים מכך מסקנה פיזיקלית גורפת בשלב זה.

• ייתכן שהדבר נובע מ:

- הבדלים ברינדור הנתונים
- ניגודיות טובה יותר בין הרחפן לרקע בתנאים אלו
- קורלציות מקריות בערכת הנתונים.

```
"weather_counts": {  
  "clear_sky": 7344,  
  "light_rain": 7456  
},  
"time_of_day_counts": {  
  "10AM": 9734,  
  "8PM": 5066
```

הטווח הקרוב טעה יותר
מאשר הטווח הרחוק

Range	Count	MAE (m)	Mean Relative Error
Near	913	16.01	49.69%
Mid	746	9.37	11.45%
Far	561	18.90	13.88%

- שילוב אופטימלי של מאפיינים: זהו הטווח שבו גם הגיאומטריה גודל ה- (Bbox) וגם רמזי העומק היחסי הם האינפורמטיביים והיציבים ביותר.
- ייצוג חזותי מאוזן: הרחפן מופיע בגודל אידיאלי בתמונה – הוא אינו גדול מדי (כמו בטווח הקרוב) ולא קטן מדי (כמו בטווח הרחוק), מה שמאפשר חילוץ מאפיינים מדויק.
- התאמה למודל ליניארי: ההנחות הליניאריות של המודל מתאימות לאזור זה בצורה המיטבית, ללא עיוותים של ערכי קצה.
- היעדר הטיות קיצוניות: בניגוד לטווח הקרוב שסבל מהטיה כלפי מעלה, טווחי הביניים קרובים לממוצע הכללי של המודל, ולכן נהנים מחיזוי יציב ומדויק יותר.

שיפורים לניסיון הבא

שיפור חילוץ העומק: השוואת חציון מול ממוצע או פיקסל מרכזי לבחירת השיטה המדויקת ביותר.

צמצום אזור הדיגום: חיתוך מרכז תיבת הגילוי למניעת זליגת רקע והפחתת רעשים במפת העומק.

כיול מפוצל: מעבר למודלים נפרדים לפי טווחי מרחק קרוב, בינוני ורחוק במקום מודל אחיד.

מודלים לא ליניאריים: הוספת משתנים פולינומיים לשיפור ייצוג הקשר בין גיאומטריה למרחק.

ייעול מאפיינים: הסרת משתנים חופפים לשיפור יציבות ופשטות המודל.

רגרסיה מתקדמת: שימוש בשיטות הסדרה להתמודדות עם ערכים קיצוניים בנתונים.

שבוע 13

6.5.26

דרישות:

- להמשיך לשפר את המודל
- התמקדות בעומק היחסי
- לבחון דרכים שונות לשימוש בעומק היחסי ולשפר אותו



השאלה:

מהו הייצוג המיטבי לעומק יחסי סביב הרחפן?

נסיון 2: ייצוג עומק יחסי

ארבעת שלבי המחקר:

1. בחירת ייצוג: מציאת השיטה המדויקת ביותר.
2. בדיקת יציבות: וידוא תוצאות על דאטה רחב.
3. שילוב קני-מידה: (Multiscale) איחוד רזולוציות לשיפור דיוק.
4. למידה ממוקדת: הפקת אותות משופרת מתכונות עומק בלבד.

המטרה

בידוד רכיב העומק ומציאת הייצוג המדויק ביותר שלו לפני שילובו במודל המלא.

המעבר מניסיון 1:

- במקום "האם כיוול עובד?", "איזה קלט ייתן את התוצאה הטובה ביותר?"
- שאלות המפתח:
 - **Crop & Summary** איזה אזור בתמונה לחתוך ואיך לסכם את ערכי העומק של הרחפן לסקלר אחד?
 - **Multiscale** האם שילוב של מספר זומים (Zooms) משפר את הדיוק?
 - **למידה מול נוסחה:** האם מודל לומד מבוסס עומק עדיף על חישוב ידני?



studies

```
▼ second attempt
  ▼ studies
    > study_01_pilot_2_per_stratum
    > study_02_expanded_10_per_stratum
    > study_03_multiscale_fusion
    > study_04_depth_only_models_30_per_stratum
```

Study 01 פיילוט: איתור מהיר של ייצוגי עומק מבטיחים על מדגם קטן.

Study 02 הרחבה: תיקוף הניתוח על מדגם רחב לוידוא יציבות התוצאות.

Study 03 multiscale zooms: בדיקה האם שילוב רמות זום שונות משפר את הדיוק.

Study 04: בניית מודל מבוסס עומק בלבד למיקסום האות לקראת המודל הסופי.




חלונות הקשר

מהו מקדם ההרחבה ?

- זהו הפקטור שבו הגדלנו את ה Bounding Box-המקורי של הרחפן . כמו zoom out הוא קובע כמה "רקע" המודל רואה סביב האובייקט.


חלוקה לקטגוריות

- מיקוד באובייקט (Tight/Local):
 - bbox_only, 1.5x, 2x
- הקשר סביבתי בינוני (Medium Context):
 - 4x, 6x, 8x
- הקשר סביבתי רחב (Wide/Global Context):
 - 10x, 16x, full_image



Full image

full_image Depth Map



Full image




2x

bbox_expand_2x Depth Map



4x

bbox_expand_4x Depth Map




שיטות אגרגציה

inner50_median: חציון של
ה-50% המרכזיים בתיבה.

bbox_mean: ממוצע של כל
שטח התיבה.

bbox_midpoint: ערך
העומק בפיקסל המרכזי בלבד.



Score Fields

• **object_depth**

- שימוש בערך העומק הגולמי שהופק מהמודל - ערך גולמי.
- **השאלה:** האם הנתון הגולמי מספיק כשלעצמו?

• **object_depth_percentile_5_95**

- נרמול הציון הגולמי לטווח האחוזונים 5-95 של החיתוך - Crop - נרמול רחב.
- **השאלה:** האם נרמול ברמת החיתוך מייצר תוצאות יציבות יותר בין תמונות שונות?


• **object_minus_ring**

- **תיאור:** חישוב ההפרש בין עומק האובייקט לעומק ה"טבעת" - Ring המקיפה אותו.
- **השאלה:** האם הניגודיות מול הרקע המיידית יציבה יותר מהערך הגולמי?


• **object_minus_ring_normalized**

- **תיאור:** הפרש העומק בין האובייקט לטבעת, מנורמל לפי טווח העומק הכולל - קונטרסט מנורמל.
- **השאלה:** האם כדאי לנרמל את הקונטרסט המקומי לפי קנה המידה הכללי של הסצנה?

Score Fields



Best MAE per Zoom after Choosing the Best Aggregation





מדדי הערכה

מדדי דיוק מרכזיים:

- **MAE:** טעות מוחלטת ממוצעת (במטרים).
- **Median Absolute Error:** טעות חציונית - עמידות בפני ערכי קיצון (Outliers).
- **Mean Relative Error:** טעות יחסית למרחק האמיתי.
- **RMSE:** מדד המחמיר עם טעויות גדולות במיוחד.

מדדים סטטיסטיים ומעשיים:

- **R^2 / Pearson / Spearman:** בחינת חוזק הקשר והמתאם בין החיזוי למציאות.
- **P90 & P95:** ניתוח מקרי הקצה (הטעויות הגדולות ביותר).
- **Hit-Rates (Within 5m/10m/20m):** אחוז הדיוק בטווחים אופרטיביים.

פילוח נתונים (Breakdowns):

- התוצאות נותחו והשוו לפי:
- **טווחים:** קרוב, בינוני ורחוק.
- **תנאי סביבה:** מזג אוויר (בהיר/גשם) וזמני יום (יום/לילה).
- **הצלבות:** ניתוח השפעת מזג האוויר והזמן על מרחקים ספציפיים.

המטרה: קבלת אינדיקציה מהירה לזיהוי "משפחת" הייצוגים המבטיחה ביותר לפני השקעה במדגמים רחבים.

היקף הדגימה: 96 תמונות (דגימה מאוזנת של 2 תמונות לכל קטגוריה).

מרחב הבדיקה (60 שיטות מועמדות):

- 5 חלונות הקשר $3 \times$ שיטות אגרגציה $\times 4$ מדדי ניקוד.

תהליך הביצוע:

- הרצת מודל העומק על כל סוגי החיתוכים (Crops).
- חישוב כלל וריאציות הניקוד והאגרגציה.
- דירוג והערכה באמצעות כיול ליניארי בשיטת Leave-one-out- בכל סבב משאירים דגימה אחת כבדיקה, ומאמנים את המודל על שאר התמונות

מחקר 01: פיילוט
ייצוגי עומק

תוצאות עיקריות: מחקר 01

RESULTS	
	Winner: bbox_only__bbox_midpoint__object_depth MAE = 25.17 m
Runner-up:	Runner-up: bbox_only__bbox_midpoint__object_depth_percentile_5_95 MAE = 26.54 m
Third:	Third: bbox_expand_1_5x__bbox_midpoint__object_minus_ring MAE = 26.76 m

- **בידוד האובייקט:** חיתוך צמוד (bbox_only) הניב את התוצאות המדויקות ביותר בשלב הראשוני.
- **מרכז המסה:** שיטת ה- midpoint התגלתה כקלט חזק יותר מהממוצע או החציון.
- **עומק גולמי:** בפיילוט, ערך העומק הגולמי (raw_depth) סיפק את האות הנקי ביותר בהשוואה למדדים מנורמלים.

מסקנות מחקר

01

באופן מפתיע, החיתוך הצמוד ביותר
(bbox_only) הניב את התוצאה הטובה ביותר.

פיקסל המרכז (midpoint) התעלה על מדדי
הממוצע והחציון.

עומק גולמי נמצא יעיל יותר מניסיונות נרמול
מורכבים.

שורה תחתונה: הממצאים סיפקו נקודת פתיחה
ברורה, אך דרשו תיקוף על מדגם רחב (Study
02) כדי לוודא יציבות.



מחקר 02: הרחבת הבדיקה ותיקוף התוצאות


- 
- הפערים בפיילוט היו קטנים מדי מכדי להסתמך עליהם. השאלה המרכזית הייתה: האם הזוכה של הפיילוט ישרוד במדגם רחב?
 - היקף הדגימה: 10 תמונות לכל שכבה ← סה"כ 480 תמונות.
 - סה"כ 7,200 שורות נתונים של ייצוגי עומק.
 - השיטות שנבחנו: אותן 60 שיטות בדיוק כמו במחקר 01 (לצורך השוואה ישירה).

תוצאות מחקר 02: אישור ויציבות הממצאים

Main result


Winner again:		
	bbox_only__bbox_midpoint__object_depth	MAE = 25.46 m Mean Relative Error = 48.1% RMSE = 31.24 m R² = 0.337
Runner-up:		
	bbox_expand_1_5x__bbox_midpoint__object_minus_ring	MAE = 26.27 m
Third:		
	bbox_only__bbox_midpoint__object_depth_percentile_5_95	MAE = 26.82 m

תוצאות מחקר 02: אישור ויציבות הממצאים



תוצאות מחקר 02: אישור ויציבות הממצאים

Winning Zoom/Method at Each Exact Distance



המסקנות הסופיות של מחקר 02

מחקר 02 הוכיח שהתוצאות אינן מקריות. המסקנות ממדגם הפיילוט שרדו גם תחת בדיקה של מדגם גדול פי 5.

הדרך הטובה ביותר לקבל נתון עומק יחיד היא בידוד מקסימלי של הרחפן (bbox_only) ושימוש בנקודת המרכז

אם רוצים להשתמש בהקשר (Context), עדיף להרחיב את החיתוך רק מעט ($\times 1.5$) ולהתמקד בניגודיות שבין הרחפן לסביבתו המיידית (object_minus_ring).

האם נוכל לשלב את החוזקות
של גידולים צפופים וגידולים
בהקשר מקומי?

מחקר 03: (Multiscale Fusion)

ההשערה : האם שילוב של מספר "זומים" יחד יעניק תוצאה טובה יותר משימוש בייצוג בודד? (בעקבות התחרות הצמודה בין bbox-only ל-1.5x).

היקף הבדיקה:

- דאטה: אותן 480 תמונות מ-02 Study
 - סה"כ שיטות לבחינה: 108 וריאציות $\leftarrow$ כ-13,000 נתונים.
- מהלך המחקר (שתי שכבות):**
- **Layer A** בחינת חלונות רחבים: בדיקה האם הוספת חלונות רחבים יותר משנה את התוצאה של מנצח בודד.
 - **Layer B** שילוב חלונות וזיהוי הצירוף המנצח: בניית וקטור המשלב ייצוגים ממספר זומים, ובדיקה באמצעות אלגוריתם (Greedy Forward OLS) אילו זומים המודל מעדיף לשלב.

תוצאות מחקר 03: (Multiscale Fusion)


MAIN RESULT

BEST SINGLE FEATURE STILL:	bbox_only__bbox_midpoint__object_depth		MAE = 25.46 m
BEST FUSION MODEL:	greedy_forward_ols_k6		MAE = 24.41 m RMSE = 30.11 m R^2 = 0.385
IMPROVEMENT VS BEST SINGLE:	MAE = -1.05 m	RMSE = -1.14 m	Mean Relative Error = -0.024
THE SIX FEATURES WERE:			
1	bbox_only__bbox_midpoint__object_depth		
2	bbox_only__inner50_median__object_depth_percentile_5_95		
3	bbox_only__inner50_median__object_depth		
4	bbox_only__bbox_midpoint__object_depth_percentile_5_95		
5	bbox_expand_2x__inner50_median__object_minus_ring		
6	bbox_expand_2x__bbox_midpoint__object_minus_ring		


- חלונות הקשר רחבים (6-16 x) והתמונה המלאה לא נבחרו על ידי המודל.
- שורה תחתונה: שילוב מקומי (Local Multiscale) הוא המפתח. אין ערך מוסף לשילוב הקשר של "כל הסצנה" בייצוג העומק.

תוצאות מחקר 03: (Multiscale Fusion)

Best Single vs Best Fusion at Each Exact Distance



- fusion helps more at the hard extremes
- the middle distance band was already relatively good



מחקר 04: מודל לומד מבוסס- עומק בלבד

המוטיבציה: מחקר 03 הוכיח ששילוב תכונות עוזר. השאלה כעת:
האם **מודל לומד** (Learned Model) יפיק אות חזק יותר מנוסחה ידנית
או שילוב ליניארי פשוט?

המודל חייב להתבסס אך ורק על עומק.

היקף הבדיקה:

- 30 תמונות לכל שכבה ← סה"כ 1,440 תמונות.
 - 108 תכונות עומק שונות (9 חלונות $\times$ 3 אגרגציות $\times$ 4 מדדים).
- מהלך המחקר (3 שלבים):**
- **Layer A** ניהול דאטה: הרחבת מאגר תכונות העומק (Caching).
 - **Layer B** השוואת מודלים: בחינת מודלים פשוטים (OLS/Ridge) מול מודלים מורכבים (Random Forest, XGBoost, Gradient Boosting).
 - **Layer C** אימות סטטיסטי: וידוא שהשיפור אמיתי ולא אקראי באמצעות 5-Fold Cross-Validation ומרווחי סמך (Bootstrap).



שכבה א': בניית מאגר תכונות

- **יעילות חישובית:** שימוש חוזר בנתונים מהמחקרים הקודמים לחיסכון בזמן ריצה.
 - **הרחבת המדגם:** חישוב משלים של נתונים חסרים עבור 1,440 תמונות.
 - **אחידות:** יצירת בסיס נתונים רחב המאפשר השוואה בין כל סוגי המודלים.
- 

שכבה ב': השוואת משפחות מודלים (Model Families)

המטרה: בחינת ארכיטקטורות שונות כדי לראות איזו מהן מצליחה "לחלץ" את המידע המדויק ביותר מנתוני העומק המנופחים.

• המודלים שנבחנו:

• Baselines

- השוואה מול התכונות הבודדות המנצחות - Best Single Features.
- משמשים כנקודת ייחוס.

• Linear Models

- מודלים ליניאריים לבדיקת קשרים ישירים - OLS, Ridge.
- בודקים האם יש קשר פשוט וישיר בין נתוני העומק למרחק. מודל ה-Ridge מוסיף "רגולריזציה שעוזרת למנוע Overfitting".

• Tree Ensembles

- מודלים מבוססי יערות החלטה - Random Forest, Extra Trees.
- מודלים אלו מסוגלים לתפוס קשרים לא-ליניאריים מורכבים ואינטראקציות בין חיתוכים שונים


• Boosting Algorithms

- אלגוריתמים מתקדמים-XGBoost, Gradient Boosting
- אלגוריתמים שלומדים מהשגיאות של עצמם באופן איטרטיבי (כל עץ מתקן את הטעויות של קודמו)


שכבה ג': תיקוף
מובהקות ומשמעות
הממצאים

- **אימות בהצלבה (5-Fold Cross-Validation):**
חלוקת הדאטה ל-5 קבוצות כדי לוודא שהמודל שומר על ביצועים עקביים ולא סובל מ-Overfitting.
- **מרווחי סמך (Bootstrap Confidence Intervals):**
שימוש בשיטות סטטיסטיות כדי לוודא שהשיפור בתוצאות הוא אמיתי ולא נובע מרעש בדאטה.
- **השוואה זוגית:** ניתוח ישיר בין המודלים המובילים כדי לקבוע מי מהם עדיף באופן מובהק סטטיסטית.


Exact-distance MAE: best single vs best linear vs best tree




Time-of-day MAE comparison



Top feature importances: RF_top_24



Top Study 4 depth-only models



תוצאות מחקר 04: המודל הלומד מנצח

- התובנה המרכזית: מודל לומד מצליח לחלץ מידע רב יותר מנתוני העומק מאשר נוסחה ידנית או שילוב ליניארי פשוט.

OBJECT DEPTH ESTIMATION: KEY RESEARCH FINDINGS



BEST SINGLE FEATURE BASELINE

bbox_only_bbox_midpoint_object_depth

CV MAE = 25.04 m

Simplest feature, lowest complexity baseline.



BEST LINEAR MULTIFEATURE MODEL

greedy_forward_ols_k8

CV MAE = 24.10 m

Improved accuracy through multiple linear features.



BEST OVERALL PERFORMER

random_forest_top_24

✓ **CV MAE = 22.95 m**

✓ **CV RMSE = 28.69 m**

✓ **CV R² = 0.441**

Top model, significantly better accuracy.



PERFORMANCE GAINS: TOP MODEL VS. BEST SINGLE

MAE = **-2.09 m**

RMSE = **-2.40 m**

Mean = **-2.00 m**


Mean Relative Error = **-0.048**



KEY INSIGHT: Both multi-feature models rely primarily on feature sets 'BB Only', 'X2', and 'X1.5'.

צלילה לנתונים

- תכונה בודדת MAE (Baseline): 25.04 מ'
 - היתוך ליניארי MAE (Greedy OLS): 24.10 מ'
 - מודל לומד MAE (Random Forest): 22.95 מ' – זהו "הגביע הקדוש" של שלב זה.
- האם השיפור "אמיתי"? (Significance):
- נעשה שימוש ב- Paired Bootstrap Comparison כדי לוודא שלא מדובר במזל.
 - התוצאה הראתה שגם במקרה הגרוע ביותר, המודל הלומד טוב משמעותית מהשיטות האחרות (דלתא של -1.48 מ' לפחות).
- מה המודל "אוהב"? (Feature Importance): גם כשהמערכת קיבלה חופש בחירה מוחלט, היא בחרה להתמקד ב:
- הליבה: חיתוך צמוד לרחפן (bbox_only), ובהקשר סביבתי מיידי בלבד
 - חיתוכים רחבים נזנחו (מעל 4 כמעט ולא תרמו לדיוק החיזוי).



סיכום ניסיון 2: מה עבד ומה נכשל?

מה עבד טוב?

- האות המנצח: חיתוך צמוד לרחפן (bbox_only), שימוש בנקודת המרכז (midpoint) ונתון עומק גולמי.
- הקשר מקומי אופטימלי: הרחבה של $1.5 \times$ בשילוב מדד ניגודיות (object_minus_ring) כחלופה יציבה.
- שילוב קני-מידה: חלון של $2 \times$ התגלה כקנה המידה היעיל ביותר לתיקון שגיאות בשילוב תכונות.
- ביצועי מודל לומד: מודלים מבוססי עצים (Random Forest) הניבו את הדיוק המקסימלי על דאטה מאוזן.

סיכום ניסיון 2: מה עבד ומה נכשל?

מה עבד פחות טוב?

- התמונה המלאה: שימוש ב- `full_image` כמקור יחיד לא סיפק אות חזק מספיק לזיהוי המרחק.
- זומים רחבים מדי: חלונות הקשר של 8×10 - $16 \times$ לא תרמו לדיוק והוסיפו רעש מיותר.
- חישובי "טבעת" על חיתוך צמוד: ניסיון לחשב ניגודיות סביבתית בתוך `bbox_only` נמצא חסר ערך (מכיוון שאין רקע בחיתוך).
- מודל ליניארי גלובלי: ההנחה שציון ליניארי פשוט אחד יפתור את כל טווח המרחקים והתנאים.

למה אנחנו חושבים ש `bbox_only` מנצח כייצוג בודד?




ריכוז האות: (Signal Dilution) בחיתוך צמוד, הרחפן תופס את מרב השטח בתמונה. ככל שהחיתוך רחב יותר, האות של הרחפן "נמהל" בתוך הרקע והופך לחלש ופחות משמעותי עבור המודל.



דיוק נקודת המרכז: (Midpoint) בחיתוך צמוד, פיקסל המרכז נוחת כמעט תמיד על גוף הרחפן עצמו. בחיתוכים רחבים, הסטייה גדלה והמרכז עלול "ליפול" על השמיים או על אלמנטים מסיחים ברקע.



מיקוד דינמי: (Scale Focus) מניעת מצב שבו אלמנטים רחוקים מאוד (כמו קו האופק או שמיים) משתלטים על סקאלת העומק. חיתוך צמוד מאלץ את המודל להקצות את כל רזולוציית העומק שלו לאובייקט בלבד.



מה הלאה?

אינטגרציה: ניקח את ה-Lower Model מ-Study 04 ונשתמש בתוצר שלו כ"תכונת עומק" (Feature) חזקה ומזוקקת.

מודל סופי : נשלב את תפוקת העומק עם האותות הגיאומטריים והמטא-דאטה מהניסיון הראשון.

בדיקת קצה: נבחן האם השילוב הסופי מצליח לשפר את הדיוק בטווחי הקצה (קרוב מאוד ורחוק מאוד), שם מודלים בודדים נוטים לזייף.

שבוע 14

27.5.26

דרישות:

- בדיקת השפעה של המרחק היחסי
- שיפור המודל
- השוואת תוצאות

22.9m

MAE (עומק בלבד)

הגשר לניסיון 3:
הפלט של מודל זה
משמש כקלט
משופר למודלים
המטריים.


הכללה מלאה :
המודל לומד לתקן
שגיאות של מפת
העומק הגולמית.

אימן מודל RF קטן
על כלל הדאטה-
סט, תוך שימוש
בתכונות העומק
הטובות ביותר
שהתגלו.


סיכום attempt 2



100m_01 | clear_sky | 10AM | HighresScreenshot00001_depth_100_clear_sky_10AM.png
BBox-only RGB crop



BBox-only depth map




30m_01 | clear_sky | 10AM | HighresScreenshot00290_depth_30_clear_sky_10AM.png

BBox-only RGB crop






BBox-only depth map



שאלה: האם באמת יש קשר בין relative depth לבין
עומק אמיתי עבור depth map רק על BB?

יחס עומק אמיתי מול עומק יחסי




יחס עומק אמיתי מול עומק יחסי

המנצח הוא BB וחישוב המiddle point
ששומר על יחס רציף


(1x) בלבד BBox + ייצוג מנצח: אמצע (נקודת אמצע)

↑ (אבל בלבד 1 BBox / אמצע) עומק יחסי




← עומק אמיתי (מסור)


Middle Table (Relative Depth)



Mean Table (Relative Depth)



Median Table (Relative Depth)





למה ניסיון 3 קיים?

ניסיון 1

נתן את קווי הבסיס של כיול מרחק מטרי באמצעות עומק גולמי, גיאומטריית bbox ומטא-דטה.

ניסיון 2

שיפר את הנדסת הפיצ'רים של העומק ובנה יער אקראי קטן שלמד אות עומק טוב יותר מכל סטטיסטיקה בודדת.

השאלה הבאה: אם ניקח את אות העומק הנלמד ונחבר אותו בחזרה למודל הכיול המלא - האם המערכת הסופית תשתפר?

זו בדיוק השאלה שניסיון 3 נבנה לענות עליה.

מבנה ניסיון 3: שלושה מחקרים

מחקר 01 - החלפת פיצ'ר ליניארית

- שמירה על מודל עליון ליניארי, החלפת עומק גולמי בפלט של ה-RF הקטן. מבחן החלפה טהור.

מחקר 02 - RF גדול למעלה

- החלפת המודל העליון ביער אקראי גדול. בדיקה האם פיצ'ר העומק עדיין עוזר כשהמודל העליון עצמו לא-ליניארי.

מחקר 03 - אגרגציה עם BBox רועש

- הוספת רעש ריאליסטי ל-bbox - הזזות וסקיילינג - ואגרגציה לפיצ'רים עמידים. מבחן ריאליזם.



מחקר 01: החלפה ליניארית מוערמת

מטרה:

לשמור על מבנה המודל הישן מניסיון 1, ולהחליף רק את ערך העומק הגולמי בפלט של ה-RF הקטן.


נתונים:

חיתוך בין שורות ניסיון 1 (14,800) לשורות ניסיון 2 מחקר 06 (15,064) = 13,864 שורות משותפות.

הסבר:

חיבור של ה-RF הקטן מ-attempt2 למודל המלא שכולל גם geometries metadata.

מחקר 01: תוצאות



• מנצח:






Stacked RF + Geometry + Metadata
(Linear)

Test MAE: 12.55 מטר

• מסקנה:

ה RF-הקטן יצר פיצ'ר עומק טוב יותר מהסקלר הגולמי, ושיפר את המודל הליניארי הסופי.

מחקר :01 תוצאות



מחקר RF:02 גדול למעלה

מטרה: מה קורה כשגם המודל העליון הוא
random forest? האם פיצ'ר העומק של ה-RF
הקטן עדיין עוזר?

סריקת עומק עצים: shallow, medium, deep,
unbounded - בדיקה היכן עצים עמוקים יותר
עוזרים ומתי מתחיל overfitting.

מחקר 02: תוצאות


מנצח:

raw_depth_geometry_metadata_rf
(rf_unbounded)




Test MAE: 7.49 מטר | שגיאה יחסית:
9.38%


תובנה מפתח: ה-RF הגדול שיפר מאוד את התוצאות, אבל המודל המוערם כבר לא ניצח - עומק גולמי + גיאומטריה + מטא-דטה ניצחו.

Study 02: Big Random Forest on Top



מחקר 02: תוצאות





מחקר 02: תוצאות

למה המודל המוערם הפסיק לנצח?

הסיבה הסבירה ביותר:

ה-RF העליון כבר יכול ללמוד תיקונים לא-ליניאריים מעומק גולמי כשהגיאומטריה נוכחת.

במחקר 01: המודל הליניארי נהנה מפיצ'ר העומק הנקי יותר של ה-RF הקטן.

במחקרים 02 ו-03: ה-RF הגדול למד מספיק תיקונים ישירות מעומק גולמי + גיאומטריה, כך שהשלב הנוסף כבר לא סיפק יתרון.

מחקר 03: אוגמנטציה + אגרגציה של BBox

מטרה: האם כשהגיאומטריה פחות מושלמת ויותר ריאליסטית, פיצ'ר העומק המוערם הופך לבעל ערך גדול יותר?


שיטה: יצירת 7 גרסאות bbox לכל תמונה (מקורי + הזזות + סקיילינג), חישוב מחדש של פיצ'רים, ואגרגציה ל-std-I median.


הקשרים: 1, 1.5x, 2x, 4x | אגרגציות עומק: bbox_mean, bbox_midpoint, median_50inner

למה זה ריאליסטי יותר: במערכת אמיתית, זיהויים לא מושלמים - תיבות יכולות להיות מוזזות, גדולות או קטנות מדי.



מחקר: 03 אוגמנטציה + אגרגציה של הBBBox

Study 03: Noisy-BBox Aggregation






Depth map (bbox_expand_2x) + exact local bbox



Depth map (bbox_expand_2x) + jittered local boxes



מחקר: 03
אוגמנטציה + אגרגציה של BBox



תוצאות מחקר 03

מנצח: raw_depth_geometry_metadata_rf
(rf_unbounded)

Test MAE: 5.2 מטר | שגיאה יחסית: 7.43%


הפתעה: הביצועים השתפרו משמעותית לעומת מחקר 02, למרות שהפכנו את ה-bbox לפחות מדויק!

הסבר: ה-median יצר אומדן מרכזי עמיד יותר, וה-std סיפק אות אמינות חדש. לא רעש - ייצוג עשיר יותר.


המודל המוערם: Test MAE של 5.33 מטר - חזק מאוד אבל עדיין לא ניצח את העומק הגולמי + גיאומטריה.

תוצאות מחקר 03

Study 03 Winner: True vs Predicted Distance



תוצאות מחקר 03



למה התוצאות השתפרו כל כך במחקר 03?

אפקט סיכום עמיד: מדידה בודדת מדויקת יכולה להיות שברירית. שימוש ב-jitter median ו-jitter std הפך כל פיצ'ר ליציב ואינפורמטיבי יותר.

מידע אמינות חדש: המודל עכשיו יודע האם פיצ'ר משתנה הרבה תחת שינויי b box קטנים - זה למעשה אות ביטחון.

ניצול נתונים מלא: מחקר 03 השתמש בכל 15,064 התמונות ישירות, לעומת תת-קבוצה קטנה יותר במחקר 02.

הטיה אינדוקטיבית טובה יותר: בניית הפיצ'רים מעודדת את המודל ללמוד אותות ששורדים רעש זיהוי ריאליסטי.

סיכום ניסיון 3

מחקר 01

- שאלה: האם ה-RF הקטן עוזר למערך הליניארי?
- מנצח: Test MAE | stacked linear : 12.55 מטר

מחקר 02


- שאלה: האם התשובה משתנה עם RF גדול למעלה?
- מנצח: Test MAE | RF + geometry raw_depth : 7.46 מטר

מחקר 03


- שאלה: האם התשובה משתנה עם bbox רועש?
- מנצח: Test MAE | RF + geometry raw_depth : 5.21 מטר

סיכום ניסיון 3


Study 01: Linear Stacked Replacement



Study 02: Big Random Forest on Top



Study 03: Noisy-BBox Aggregation



מה אנחנו חושבים שהתוצאות אומרות

1. ה-RF הקטן באמת משפר את אות העומק -
עומק גולמי לבד חלש, עומק RF הרבה יותר טוב.
2. הגיאומטריה עדיין האות הדומיננטי - גם אחרי
הוספת רעש, פיצ'רים מבוססי גיאומטריה הם בעלי
החשיבות הגבוהה ביותר.
3. ה-RF העליון לומד את רוב התיקונים בעצמו -
לכן המודל המוערם מפסיק לנצח עם מודל עליון
חזק.
4. אגרגציה רועשת עזרה בזכות עמידות - לא רק
"הכנסת רעש" אלא יצירת ייצוג עשיר ויציב יותר.

שאלות פתוחות

1. האם המודל המוערם ינצח עם רעש גיאומטרי חמור יותר?
(bbox גרוע יותר, אסימטרי, מרכז שגוי)
2. האם מודל עליון אחר (XGBoost, ExtraTrees, boosting) ינצל טוב יותר את אות העומק?
3. כמה מההצלחה הנוכחית ספציפית לדאטהסט הזה? האם זה יעבוד על נתונים חדשים לגמרי?
4. האם ניתן להפוך את הגיאומטריה לריאליסטית עוד יותר? (פלט דטקטור אמיתי במקום jitter מבוקר)
5. האם מידע טמפורלי (עקביות בין פריימים, רמזי תנועה) ישנה את האיזון בין עומק לגיאומטריה?

שבוע 15

3.6.26

דרישות:

- לשפר את המודל עוד
- לנסות לטפל בBBox שיהיו יותר ראלים
- ניסוי על תמונות אמיתיות

ניסיון 4



Noisy-BBox, שורות מורחבות,
XGBoost ושילוב RF+XGB



3 מחקרים | | Random Forest
XGBoost | Blend

ניסיון 4


study1: ליצור בייסליין שיבדוק איך RF מתמודד עם נתונים רועשים שאינם מקובצים.

study2: לבדוק אם אלגוריתם שונה (xgboost) יביא תוצאות טובות יותר על אותם נתונים.

study3: לבדוק אם שילוב התחזיות של שני המודלים יקזז שגיאות וישפר את הדיוק.

מחקר 01

Depth map (bbox_expand_2x) + jittered local boxes



הבעיה :


בניסיון 3 אמנם יצרנו רעש בקופסאות, אבל אז עשינו להן מיצוע (Aggregation) וקיבצנו אותן לשורה אחת "נקייה" ויציבה לכל תמונה. זה עשה למודל חיים קלים מדי ויצר ייצוג מדויק ובטוח מדי שלא קיים בשטח.

מחקר 01

המטרה במחקר: לבחון האם מודל מסוג Random Forest יכול לקבל קופסה בודדת, מורעשת ולא מושלמת (כפי שקורה במציאות) ועדיין לחזות את המרחק בהצלחה.


הפתרון: הפסקת הקיבוץ. כל וריאציה רועשת ופגומה של הקופסה (למשל, מוקטנת או מוגדלת מדי) הופרדה ונשמרה כשורה עצמאית (Expanded Rows).

תוצאות מחקר 01: Random Forest



המנצח: CV raw_depth_geometry_metadata_rf
m | Mean 7.7124 m | Test MAE: 7.7907 OOF MAE:
0.0990 Relative Error:

מחקר 01: תובנות מפתח



מחקר 02

XGBoost

נראה אם החלפת אלגוריתם הלמידה ל-XGBoost תצליח לחלץ סיגנל חזק ומדויק יותר מתוך בדיוק אותה טבלת תכונות ואותם פיצולים.





למה מחקר 02?

אם נשמור את אותו feature table מדויק ממחקר 01,
אבל נחליף את Random Forest ב-XGBoost - האם
נקבל לומד חזק יותר?


תוצאות מחקר XGBoost:02

המנצח: raw_depth_geometry_metadata_xgb

CV OOF MAE: 7.7536m

Test MAE: 7.7301m

Mean Relative Error: 0.1014



מחקר 03

שילוב RF + XGBoost

מאחר ש RF + XGBoost-הציגו רמות דיוק דומות בסך הכל, השאלה הייתה האם כל אחד מהם עושה טעויות במקומות קצת אחרים.

אם כן, מיצוע של התחזיות שלהם אמור להניב תוצאה חזקה ויציבה יותר מאשר כל אחד בנפרד.


המחקר לא אימן את המודלים מחדש. במקום זאת, הוא טען את התחזיות המנצחות משני המחקרים הקודמים, יישר אותן לפי מזהה שורה, וביצע חיפוש Grid Search כדי למצוא את משקל השילוב האופטימלי (Convex Blend) על סט האימות.

למה לשלב RF ו-XGBoost?

• RF ו-XGBoost קרובים ב-MAE הכולל, אבל
האם הם עושים שגיאות שונות מספיק כדי
שממוצע שלהם יעזור?



תוצאות מחקר 03: שילוב



Tuned Blend: CV OOF MAE 7.6325m
האופטימלי שנמצא היה 44% למשקל ה-RF ו-56%-ל-XGBoost.

Equal Blend: Test MAE 7.6770m



RF alone: Test MAE 7.7124m

XGB alone: Test MAE 7.7301m

שיפור מול RF: 0.08m | שיפור מול XGB: 0.10m
בלבד tuned blend ל-equal: 0.002m הפרש בין

המסקנה: השילוב עובד

תוצאות מחקר 03: שילוב





ניסיון 5



ייצוא מודל, הערכה על Nenrus, וכיול
ניסיון 4 נתן תוצאות מצוינות ברמת
האנליזה, אבל לא הפיק מודל מוכן להפעלה
(Deployable).

ניסיון 5 נוצר כדי לארוז את המודל למוצר
מוגמר לבחון אותו במבחן האולטימטיבי על
צילומי רחפנים אמיתיים ממקור חיצוני
לחלוטין (Nenrus) ולפתור פערים ביכולת
ההכללה (Generalization) שלו לעולם
האמיתי.


למה ניסיון 5 קיים?

ניסיון 4 מצא את המודל הטוב ביותר,
אבל לא שמר artifacts מאומנים.

ניסיון 5 הופך את האנסמבל לחבילת
inference שמישה.

בדיקה על תמונות דרון אמיתיות:
הרצה על נתונים חיצוניים מ-Nenrus.

כיול: לימוד והערכת פונקציות כיול
לתיקון שגיאות שיטתיות.



מפת המחקרים - ניסיון 5

מחקר 01-02: ייצוא RF, XGBoost, metadata
אנסמבל ו-schema. הרצת האנסמבל הקפוא על
Nenrus (דרונים אמיתיים).

מחקר 03: בדיקה אם דגש על עומק יחסי פותר
את הבעיה.

מחקר 04: לימוד והערכת פונקציות כיול.

מחקר 01

כדי לבצע מבחן חיצוני אמיתי מבלי לחשוש מאימון יתר או מזליגת נתונים חובה, "להקפיא" את המודל שניצח בניסיון 4 ולארוז אותו לשימוש עתידי.

למה מחקר 01?

מחקרי ניסיון 4 שמרו דוחות, תחזיות ומדדים - אך לא שמרו את אובייקטי המודל המאומנים. כדי להריץ על נתונים חדשים, צריך לייצא את המודלים.

הערכה חיצונית על Nenrus

כדי לבדוק האם המודל, שאומן על נתונים סינתטיים/ספציפיים, מסוגל להכליל ולנבא מרחקים במדויק על צילומים של רחפנים אמיתיים מסביבה שונה לחלוטין.

הרצה "עיוורת" של המודל הקפוא ממחקר 5.1 על 489 התמונות מהדאטה-סט של Nenrus, ללא כל כוונן או אימון מחדש.

מחקר 02

מחקר 02: דוגמה לתמונות

- Kongsberg
- Vestfold

Vestfold | 40m | class 0




Kongsberg | 9m | class 0



תוצאות מחקר :02 Nenrus

MAE by Distance



MAE: 26.11m | RMSE: 30.48m | R2: -1.45

שגיאה יחסית ממוצעת: 1.00

שיעור overprediction: 100%

Within 10m: 7.57% בלבד


Kongsberg: MAE 36.15m

Vestfold: MAE 18.98m


המודל נכשל - חיזוי מרחקים גדולים מדי באופן
שיטתי

מקום לגרף: Predicted vs True - Nenrus

בעיית ה- Domain Shift



אי-התאמת קנה מידה של BBox



מחקר 03

בדיקת משקל עומק יחסי

אם הבעיה היא שהגיאומטריה הפיזית משתנה בין הדאטה סטים, אולי ניתן לתקן זאת על ידי הכרחת המודל להסתמך יותר על נתוני העומק (שאמורים להיות אדישים לגודל הפיזי של הרחפן)?

מחקר 03: דגש על עומק יחסי


depth_only עומק בלבד: (מחיקה מוחלטת של כל הפיצורים הגיאומטריים פיקסלים, שטח, יחס גובה-רוחב. (המודל אולץ להסתמך אך ורק על הסקלר של העומק היחסי.

depth_plus_no_size_geometry השארת פיצורים גיאומטריים שאינם מושפעים מגודל הרחפן) כמו מיקום מרכז הקופסה X ו- Y על המסך, (תוך השמטת פיצורי הרוחב, הגובה והשטח.

depth_plus_normalized_geometry החלת נרמול מתקדם על הפיצורים הגיאומטריים כדי לנסות לצמצם את פער קנה המידה) קנ"מ (מול נתוני העומק.

-depth_repeated_8_with_geometry
depth_repeated_16_with_geometry שימוש בטריק אלגוריתמי. מאחר שמודלים מבוססי-עצים (RF) ו(XGBoost) בוחרים פיצורים לפי מידת ההפחתה באנטרופיה, MSE/שכפול פיזי של עמודת העומק 8 או 16 פעמים בתוך הדאטה-סט מעלה באופן מלאכותי ודרמטי את ההסתברות שהעצים יבחרו לפצל את הצמתים על בסיס נתוני העומק ולא על בסיס הגיאומטריה הדומיננטית.

MAE by Distance for Selected Depth-Weighted Variants



כיוול (Calibration)

מחקר 04

מכיוון שאימון מחדש אינו רצוי
והסתמכות על עומק בלבד לא
עבדה, היה צורך בשכבה קטנה
וחכמה שתיקח את התחזית
הגולמית (והמוגזמת) של המודל,
ותמפה אותה חזרה לסולם
המרחקים הנכון במציאות.




למה כיול? במקום לאמן מחדש
את RF/XGBoost, אפשר להוסיף
שכבת תיקון קטנה מעל התחזית
הגולמית. פונקציה פשוטה
שממפה תחזיות גולמיות
למרחקים מדויקים.

תוצאות מחקר 04: כיוול

per_drone_quadratic: MAE 3.03m 3.0251 :EAM | m | RMSE:
4.1104m | R2.0153 :EA naideM |0.9555 :2m Within 2m:
5 nihtiW |49.28% m: 10 nihtiW |79.75% m: nihtiW |97.14%
20m: 100%

Overprediction rate: (מאוזן) 47.85%Kongsberg: MAE 36.15m
2.76 →m Vestfold: MAE 18.98m 3.22 →m



Kongsberg:

$$\text{calibrated} = -6.80505587275528 + 0.6521277411976535 * p - 0.001466649376865686 * p^2$$

Vestfold:

$$\text{calibrated} = -11.71790602892214 + 1.0996974109541213 * p - 0.003059627825357708 * p^2$$

